C-Kurs Dynamische Speicherverwaltung

Speicher – Abstraktion

- Speicher:
  Virtueller Speicher: Ein Bytearray
- Programmsicht:
  - Jedes Programm hat seinen eigenen Speicher
  - Es hat eine „unbegrenzte Speichermenge“
  - Der Zugriff auf alle Speicherbereiche ist gleich schnell, ...

Speicher – Realität

- Speicher:
  Virtueller Speicher: Ein Bytearray
- Realität:
  - Kein unbegrenzter physikalischer Speicher
    - Alle Programme teilen sich den selben physikalischen Speicher
    - Speicher wird durch das Betriebssystem allokiert und verwaltet
    - Viele Anwendungen sind speicherdominiert
    - Es gibt eine Speicherhierarchie: Cache, RAM, Platte

- Speicherzugriffsfehler sind besonders problematisch
  - Effekte sind oft weit von der Ursache entfernt

Speicher und C-Programme

Speicher und C-Programme

- Prinzip: Zuteilung von Speicher nach Bedarf, da begrenzte Ressource
- Programmkomponenten die Speicher brauchen
  - Der ausführbare C-Code – das Programm
  - C-Bibliotheken und externe Funktionen, z.B. printf
  - ...

Speicher und C-Programme
Physikalischer Speicher

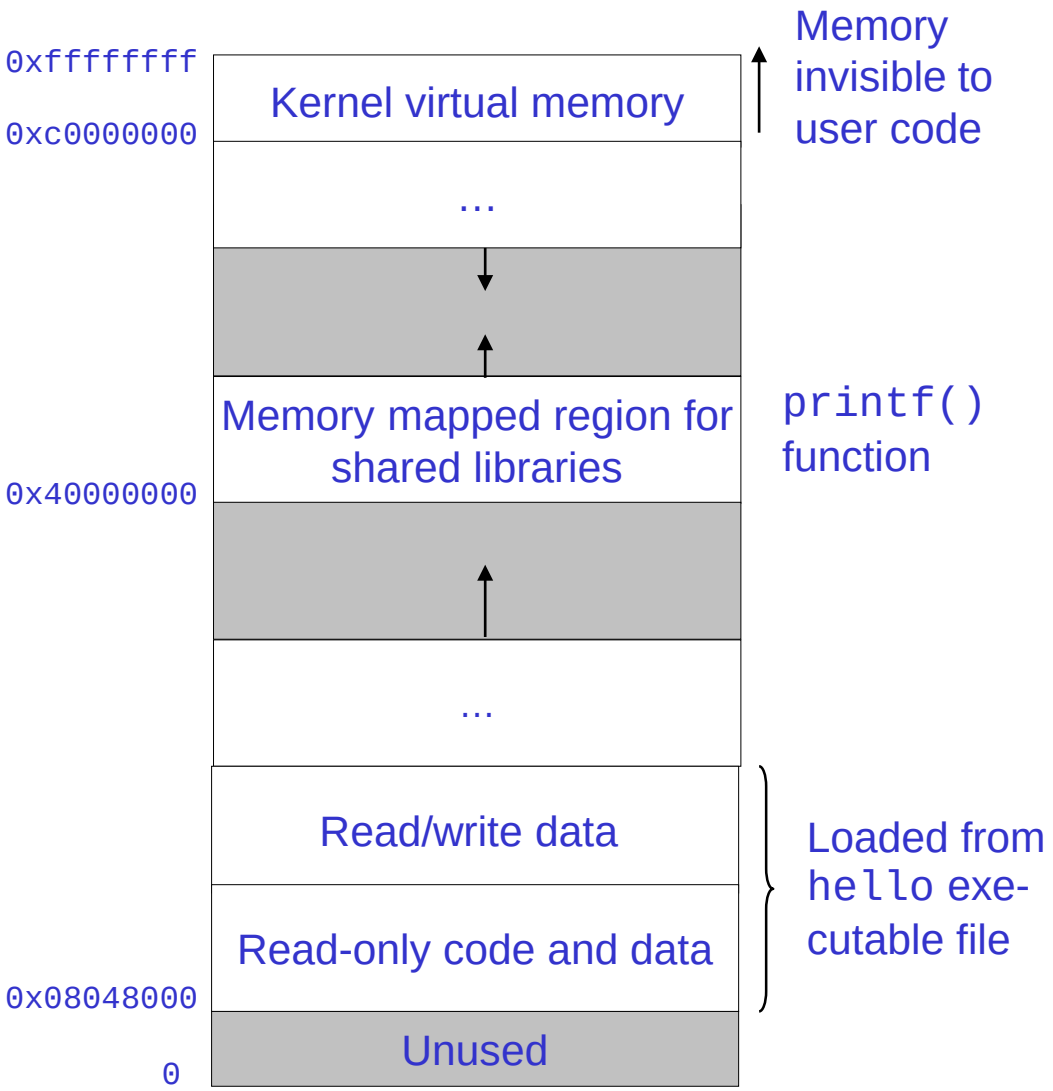

C-Speicher – implizit

- Prinzip: Zuteilung von Speicher nach Bedarf, da begrenzte Ressource
- Programmkomponenten die Speicher brauchen
  - C-Code selber
  - C-Bibliotheken und externe Funktionen, z.B. printf
  - Implizit für C-Variablen, C-Arrays und C-Funktionen
  - ...
- Problematik
  - Speicher für C-Funktionen unbekannt vor Programmaufruf
  - Warum: Funktionsaufrufreihenfolge unbekannt
- Konzept
  - Speichern der Variablen, etc in einem dynamisch wachsenden Datenstruktur (Hier Stack – mehr zu der Datenstruktur Stack später)

Speicher und C-Programme
Physikalischer Speicher

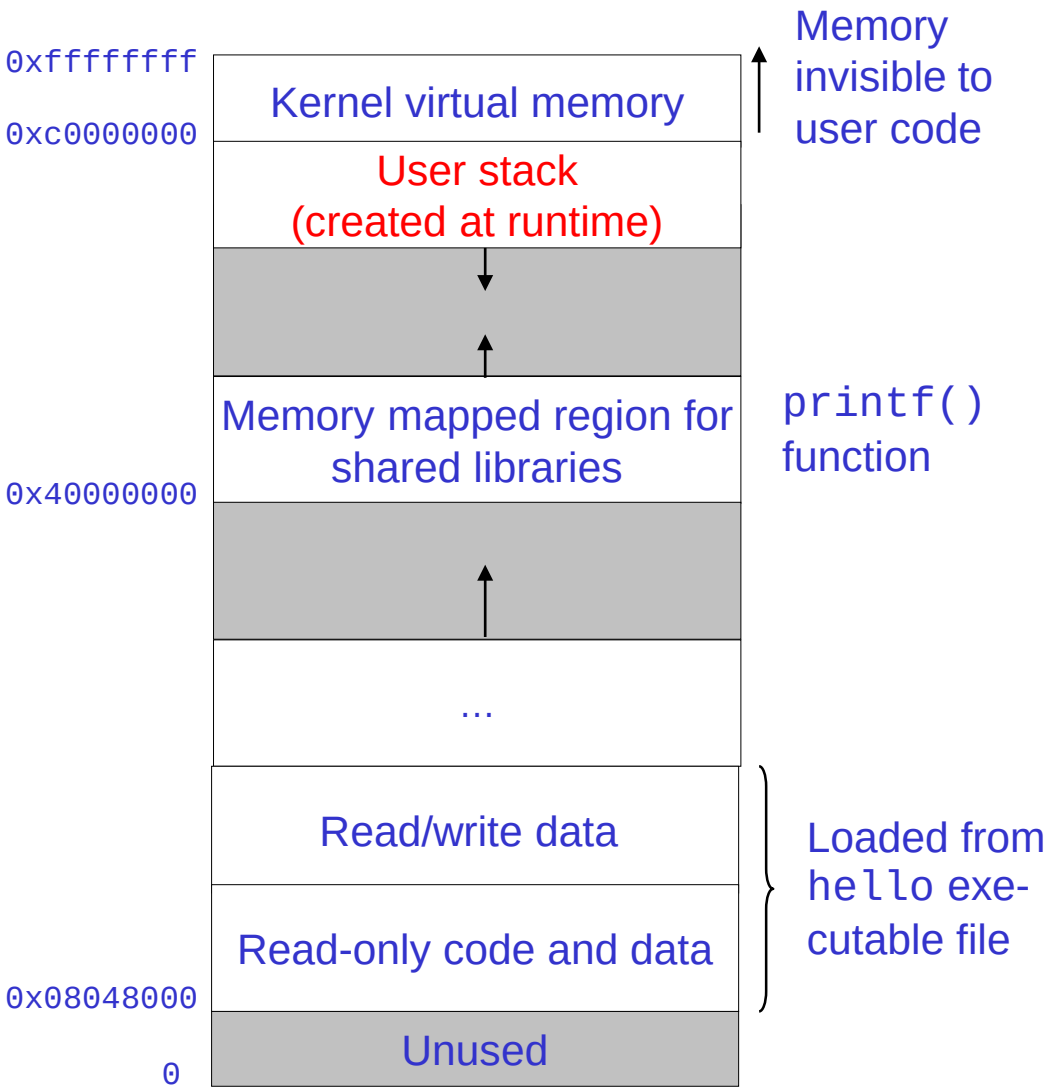

C-Speicher – explizit

- Prinzip: Zuteilung von Speicher nach Bedarf, da begrenzte Ressource
- Programmkomponenten die Speicher brauchen
  - C-Code selber
  - C-Bibliotheken und externe Funktionen, z.B. printf
  - Implizit für C-Variablen und C-Funktionen
  - **Explizit für C-Variablen, wenn die benötigte Menge Speicher von Parametern abhängig ist**
- Problematik
  - Speicherbedarf für C-Variablen unbekannt vor Programaufruf
  - Warum: Anforderungen unbekannt
- Konzept
  - **Speichern der Variablen, etc. in einer weiteren dynamisch wachsenden Datenstruktur** (einem Heap – mehr zu der Datenstruktur Heap später)

Speicher und C-Programme
Physikalischer Speicher

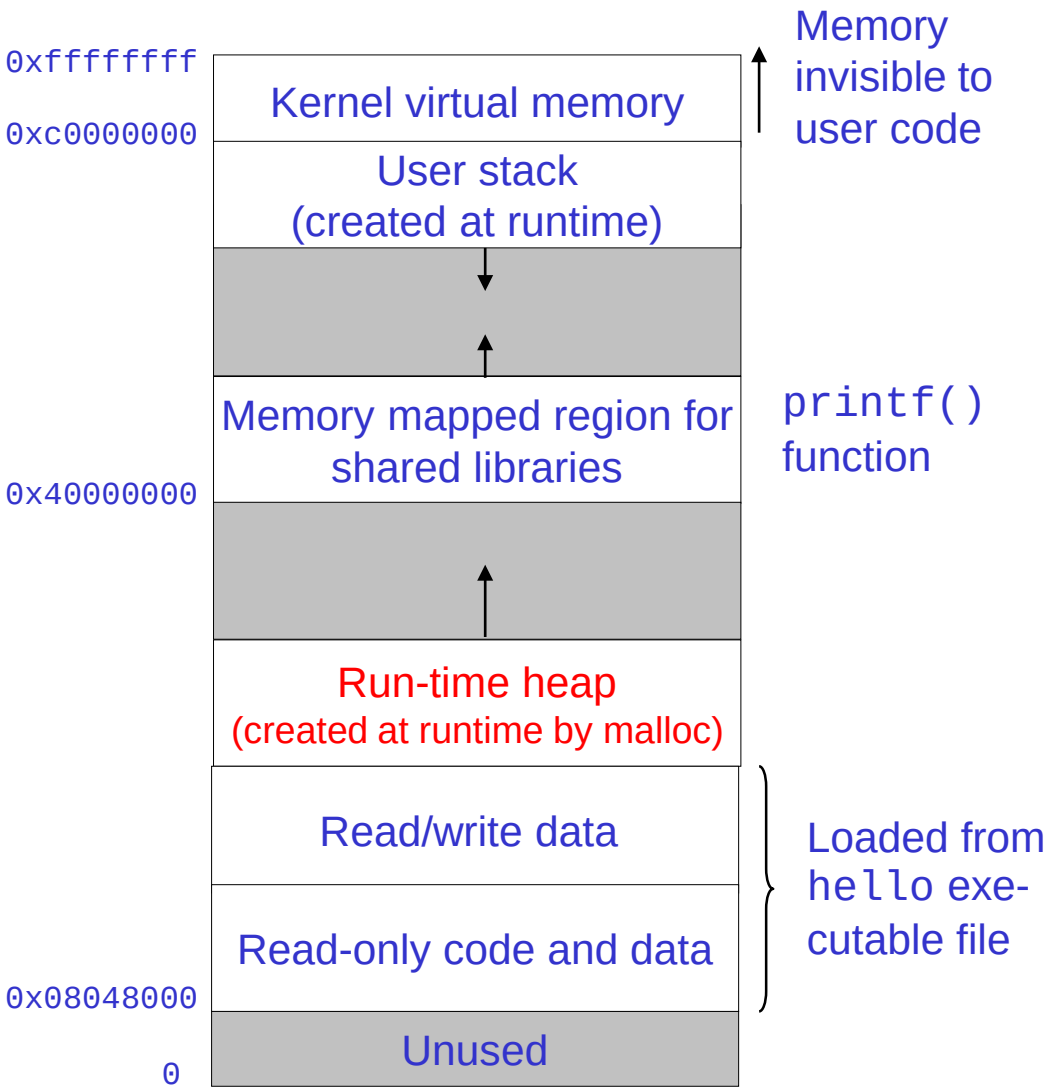

Laufzeit vs. Compilezeit

- Compilezeit
  - Während des Compilieren d.h.: Übersetzen des C-Codes in Assemblercode
- Laufzeit
  - Während der Ausführung eines compilierten Programms

- Beispiele:
  - Welche Funktionen existieren: Bekannt zur Compilezeit
  - Wie häufig eine Funktion ausgeführt: idR: Bekannt zur Laufzeit
  - Mit welchen Funktionsparametern: idR: Bekannt zur Laufzeit

Dynamische Speicherallokation in C

Dynamische Speicherallokation

- Prinzip: Zuteilung von Speicher nach Bedarf, da begrenzte Ressource
- Zwei Varianten der Speicherverwaltung
  - Implizit
    - C Variablen

```
int a[100]; // Die benötigte Menge Speicher
            // steht zur Compilezeit fest
```

  - Explizit, z.B: für ein Array mit zur Compilezeit unbekannter Länge, welches abhängig von den Eingabedaten ist
    - C Speicherverwaltung: **`malloc`** und **`free`**

Memory ALLOCation in C

`malloc`

Dynamische Speicherverwaltung: malloc

- `#include <stdlib.h>`
- `void *malloc(size_t size)`
  - Rückgabe:
    Zeiger auf Speicherblock der wenigstens die Größe **`size`** Bytes hat. Allignment (typischerweise) auf 8-Byte Grenzen
  - Speicher wird nicht (mit 0) initialisiert

Einschub: Rückgabewerte im Kontext der Fehlerbehandlung

- Motivation:
  - In jeder Funktion können Fehler auftreten
  - Wie werden diese an die aufrufende Funktion zurückgemeldet?
  - Z.B: Speicher ist endlich: malloc ist nicht in der Lage die gewünschte Speichermenge zu allokieren
- Idee – Nutzen von Rückgabewerten
- Falls Fehler in der Funktion auftritt:
  - Explizite Rückgabe eines bestimmten Wertes
  - Setzen eines Fehlercodes in der globalen Variable **`errno`**
  - Nutzen einer Hilfsfunktion **`perror`**. Um diesen Fehlercode und die Fehlermeldung auf der Konsole (genauer **`stderr`**) auszugeben

Einschub: Fehlerbehandlung

- Motivation:
  - In jeder Funktion können Fehler auftreten
  - Gewisse Fehler sollen zum Abbruch des Programms führen
- Idee – Nutzen der Abbruchfunktion `int exit()`
- Falls Fehler in einer Unterfunktion auftritt:
  - Erst Fehleranalyse
  - Dann Abbruch des Programms mittels `exit`
    - Argumentwert > 0
  - Bricht das Programm vollständig ab
  - Erfolgreiche Ausführung eines Programms gibt den Wert 0 zurück (Erinnerung: `int main()`)

Malloc: Beispiel ohne und mit Fehlerbehandlung

```
char *foo(int n){                    // not to be used!
  char *p;
  // allocate a block of n bytes
  p=(char *) malloc(n);
  return p;
}
```

```
char *foo-with-error-handling(int n){  // to be used
  char *p;
  // allocate a block of n bytes
  if ((p = (char *) malloc(n)) == NULL){
    perror("malloc failed while allocating n chars");
    exit(1);
  }
  return p;
}
```

Malloc: Beispiel mit Fehlerbehandlung

```
char *foo-with-error-handling(int n){  // to be used
  char *p;
  // allocate a block of n bytes
  // if ((p=(char *) malloc(n))) == NULL){

  p=(char *) malloc(n);
  if (p == NULL){

    perror("malloc failed while allocating n char");
    exit(1);
  }
  return p;
}
```

Beispiel: möglicher Speicherzugriffsfehler

```
char *foo(int n){                    // not to be used!
  char *p;
  // allocate a block of n bytes
  p=(char *) malloc(n);
  return p;
}
```

- Fehlerbehandlung wichtig, weil sonst Speicherzugriffsfehler möglich sind
- Hier ein Zugriff auf ein nicht allokiertes Array
- Zugriff auf „Nullpointer“ => Core dump

Einschub: Rückgabewerte Hier zwei C-Konventionen

- Funktion hat eigentlich keinen Rückgabewert
  - Z.B.: `int add (int *sum, int a, int b)`
  - Alles OK => Rückgabe des Wertes 0
  - Fehler => Rückgabe eines Wertes != 0

- Funktion hat einen Rückgabewert
  - Z.B.: `void *malloc(size_t size)`
  - Alles OK => Rückgabe eines Wertes != 0
  - Fehler => Rückgabe des Wertes `NULL` == 0

- Zusätzlich: Setzen des Fehlercodes in `errno`.
  - Nutzen einer Hilfsfunktion `perror`. Um diesen Fehlercode und die Fehlermeldung auf der Konsole (genauer `stderr`) auszugeben

Dynamische Speicherverwaltung: malloc

- `#include <stdlib.h>`
- `void *malloc(size_t size)`
  - Falls erfolgreich:
    - Rückgabe: Zeiger auf Speicherblock der wenigstens die Größe `size` Bytes hat. Allignment (typischerweise) auf 8-Byte Grenzen
    - Falls `size == 0`, Rückgabewert NULL
  - Falls nicht erfolgreich: Rückgabe NULL (0) und setzen von `errno`.
  - Speicher wird nicht (mit 0) initialisiert

- `void perror(msg)`
  - Gibt die letzte Systemfehlermeldung auf der Konsole (genauer `stderr`) aus

Einschub: Was ist void?

- Motivation:
  - Viele Funktionen geben nichts zurück.
  - Z.B:
```
void print_hello () {
        printf(„hello world\n“);
}
```
- Problem – C-Syntax verlangt, dass jede Funktion einen Rückgabewert hat
- Idee – Nutzen eines „generischen Typ“: `void`

Einschub: Was ist void *?

- Motivation:
  - Viele Funktionen interessiert es nicht, ob sie einen Pointer auf int oder auf double, oder sonst einen Datentyp bekommen oder zurückgeben.
  - Wichtig ist, dass es ein Pointer ist.
- Idee – Nutzen eines „generischen Pointertyps“: `void *`
- Beispiel: `void *malloc(size_t size)`
- Kann dann in den gewünschten Typ umgewandelt („casting“) werden:
  - `char *p-char = (char *) p = *malloc(12);`
  - `int *p-int = (int *) p = *malloc(12);`
  - `float *p-float = (float *) p = *malloc(12);`

Dynamische Speicherverwaltung: free

- `#include <stdlib.h>`
- `void free(void *p)`
  - Der Block auf den `p` zeigt wird an den verfügbaren Speicherpool gegeben
  - `p` Resultat eines vorherigen Aufrufes von `malloc` oder `realloc`

- Hinweise: Es gibt in C keine Garbagecollection!
  - Speicher muss explizit freigegeben werden!
  - Speicher wird nicht automatisch auf 0 gesetzt

Bestimmung der Speichergrößen

- Operator: `sizeof`
- Ermittelt Größe von Typ / Variablen in Bytes
- Beispiel:

```
long l;
sl = sizeof(l);
sd = sizeof(double);
```

- Beispiel: Sun Sparc 32 Bit

```
char 1 Byte
short 2, int 4, long 4, long long 8 Bytes
float 4, double 8, long double 16 Bytes
pointer 4 Bytes
```

Datendarstellung

- Größen von C Objekten (in Bytes)

C Data Typ	Typical 64-bit	Typical 32-bit	Intel IA32
int	4	4	4
long int	8	4	4
char	1	1	1
short	2	2	2
float	4	4	4
double	8	8	8
long double	8	8	10/12
char *	8	4	4
Oder jeder andere Pointer	8	4	4

- Operator sizeof()
  Ermittelt Größe vom Typ / Variablen in Bytes

Typumwandlung in Ausdrücken

- Sind unterschiedliche Typen in Ausdrücken enthalten wird eine implizite Typumwandlung gemacht

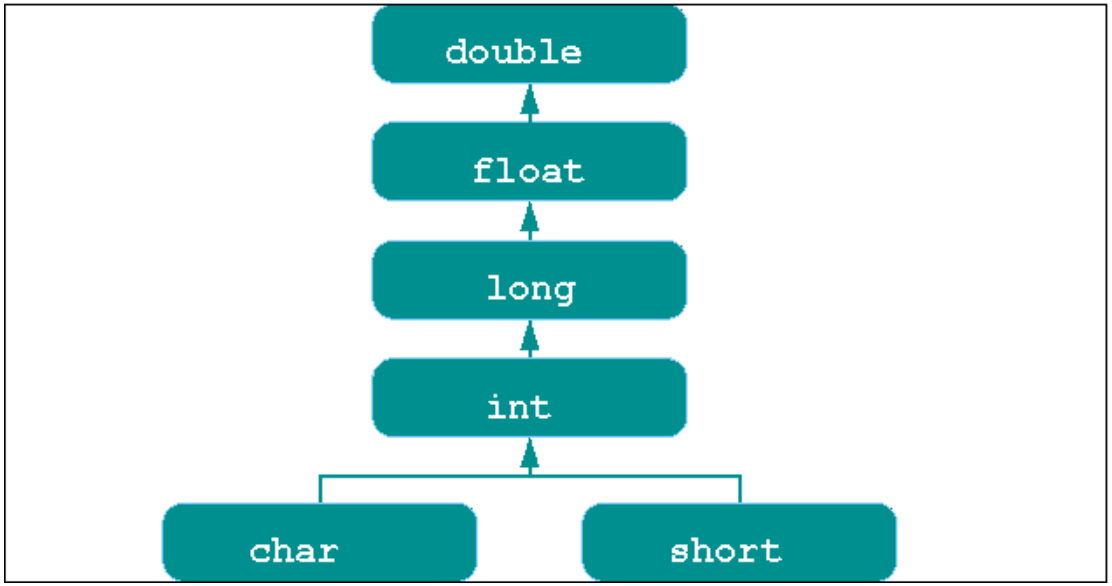

- Explizite Typumwandlung mittels Casting:

```
(type) expr
```

Malloc/free: Beispiel

```
void foo(int n){
  int i, *p;

  /* allocate a block of n ints */
  if ((p=(int *) malloc(n*sizeof(int))) == NULL){
    perror("malloc failed when allocating n ints");
    exit(1);
  }
  for (i = 0; i < n; i++){
    p[i] = i;
  }
  free(p); /* return p to available memory pool */
}
```

Dynamische Speicherverwaltung: calloc

- `#include <stdlib.h>`

- `void *calloc(size_t n, size_t size)`
  - Falls erfolgreich:
    - Rückgabe: Zeiger auf Speicherblock der wenigstens die Größe `n * size` Bytes hat. Allignment (typischerweise) auf 8-Byte Grenzen
  - Falls nicht erfolgreich: Rückgabe NULL (0) und setzen von `errno`
  - Speicher wird mit 0 initialisiert

Arrays und Pointer

Arrays und Pointer

- Bekannt:
  Arrays und Pointer werden in C ganz ähnlich behandelt
- Wesentlichster Unterschied:
  - Arrays haben eine feste Dimension
    - ⇨ Ihnen ist ein fester Speicherort zugeordnet
    - ⇨ Für die zu speichernden Objekte / Arrayelemente ist Platz reserviert
  - Zeiger/Pointer weisen erst nach Zuweisung oder dyn. Allokation auf den Speicherort ihrer Objekte
- Arrayvariable ⇨ Adresse des 1. Elements
- Arrayindizes ⇨ Offset im Array

Arrays und Pointer

- Konstante Dimension/Größeangabe von Arrays

```
double df[100];  /* Array mit 100 Elementen */
```

- Variable Dimensionierung von Arrays nur für lokale/automatische Arrayvariable zulässig

```
void fun(int n) {
  double df[n];  /* Array mit n Elementen */
  ...
}
```

- Grund: Arraygröße muss beim Anlegen / bei Speicherzuweisung des Arrays bekannt sein
  - Statisch / global ⇨ Compile-Zeit
  - Automatisch / lokal ⇨ Eintritt in Funktion / Block

Arrays und Pointer

- Variable Dimensionierung von Arrays wird häufig benötigt
- Lösung ⇨ dynamische Arrayallokation
- Beispiel: **`double`**-Array dynamisch duplizieren

```
double *dbldup(double d[], int n) {
  double *df;
  int i;

  df = (double *) malloc(n *sizeof(double));
  for(i = 0; i < n; i++){
    df[i] = d[i];}
  return(df);
}
```

Arrays und Pointer

- Arraynamen sind eigentlich Pointer, zeigen auf das erste Element im Array

```
int i, *ip, ia[4] = {11, 22, 33, 44};
ip = ia;
```

Arrays und Pointer

- Arraynamen sind eigentlich Pointer, zeigen auf das erste Element im Array

```
int i, *ip, ia[4] = {11, 22, 33, 44};
ip = ia;
i = *++ip;
```

- Ähnlichkeit von Arrays und Zeigern
  - ⇨ macht die Pointerarithmetik möglich
  - ⇨ Pointerarithmetik mächtig, aber oft unübersichtlich

Arrays und Pointer

- Arraynamen sind eigentlich Pointer, zeigen auf das erste Element im Array

```
int i, *ip, ia[4] = {11, 22, 33, 44};
ip = ia;
i = *++ip;
```

- Ähnlichkeit von Arrays und Zeigern
  - ⇨ macht die Pointerarithmetik möglich
  - ⇨ Pointerarithmetik mächtig, aber oft unübersichtlich
- Arrayindizes sind Offsets == Abstand zum Arrayanfang

```
ia[3]   ⇨   *(&ia[0] + 3)
```

- Hinweis: Pointerarithmetik ist mit Vorsicht zu genießen und hier nur der Vollständigkeit halber erwähnt.